

Recuperação de Informação

Programa de Pós-Graduação para Engenheiros - USIMINAS

Prof. Dr. George Henrique Godim da Fonseca

Copyright © 2020 Universidade Federal de Ouro Preto

PUBLICADO PELO PROGRAMA DE PÓS-GRADUAÇÃO EM ENGENHARIA DE PRODUÇÃO DA UNIVERSIDADE FEDERAL DE OURO PRETO (PPGEP-UFOP) - ICEA/DEENP

PPGEP - UFOP / ICEA (CAMPUS: JOÃO MONLEVADE) - URL: HTTPS://PPGEP.UFOP.BR

ESTRUTURAÇÃO DO DOCUMENTO EM LATEX: **JÚLIO CÉSAR ALVARENGA**
DISCENTE DO PPGEP-UFOP - ÁREA: PESQUISA OPERACIONAL - LINHA DE PESQUISA: MODELAGEM DE SISTEMAS PRODUTIVOS E LOGÍSTICOS (MSLP)

Primeira impressão, Outubro 2020

Sumário

I Parte III

1 Introdução à Recuperação da Informação 6

1.1 Tipos de Sistemas de Recuperação da Informação 7

1.2 Modelos de Interação em RI 7

1.3 Visão Geral de Recuperação da Informação 8

1.3.1 Arquitetura de um Sistema de RI 8

1.3.2 Processo de Recuperação e de Ranqueamento 9

1.4 Recuperação de Informação na Web 11

1.4.1 Algoritmo Page Rank 11

1.5 Exercícios 12

2 Indexação e Pré-processamento 13

2.1 Representação dos Documentos 14

2.1.1 Matriz de Termos 14

2.1.2 Índice Invertido 14

2.2 Visão Lógica dos Documentos 15

2.3 Pré-processamento de Texto 15

2.3.1 Remoção de *Stopwords* 16

2.3.2 *Steeming* 16

2.3.3 Vocabulário Controlado 16

2.3.4 Acentos, dígitos, hifens e sinais de pontuação 17

2.4 Exercícios 17

3 Modelagem em RI 19
3.1 Modelagem e Ranqueamento 19
3.1.1 Caracterização de um Modelo de RI 19
3.2 Modelo Booleano 20
3.3 Ponderação de Termos 21
3.3.1 Correlações entre Termos 22
3.4 Ponderação TF-IDF 22
3.4.1 Ponderação da Frequência de Termos 22
3.4.2 Ponderação da Frequência Inversa de Documentos 23
3.4.3 Ponderação TF-IDF 24
3.5 Normalização pelo Tamanho dos Documentos 25
3.6 Modelo Vetorial 26
3.7 Modelo Probabilístico 27
3.7.1 Tabela de Contingência das Incidências de Termos 28
3.8 Exercícios 30

4 Avaliação da Recuperação 31
4.1 Métricas de Recuperação 32
4.1.1 Precisão e Revocação 32
4.2 Métricas de Avaliação 35
4.2.1 Média das Precisões Médias 35
4.2.2 Curva de Precisão vs. Revocação 35
4.2.3 F-score 36
4.3 Exercícios 37

Bibliografia 38
Artigos 38
Livros 38

Parte III

1 Introdução à Recuperação da Informação 6

1.1 Tipos de Sistemas de Recuperação da Informação
1.2 Modelos de Interação em RI
1.3 Visão Geral de Recuperação da Informação
1.4 Recuperação de Informação na Web
1.5 Exercícios

2 Indexação e Pré-processamento 13

2.1 Representação dos Documentos
2.2 Visão Lógica dos Documentos
2.3 Pré-processamento de Texto
2.4 Exercícios

3 Modelagem em RI 19

3.1 Modelagem e Ranqueamento
3.2 Modelo Booleano
3.3 Ponderação de Termos
3.4 Ponderação TF-IDF
3.5 Normalização pelo Tamanho dos Documentos
3.6 Modelo Vetorial
3.7 Modelo Probabilístico
3.8 Exercícios

4 Avaliação da Recuperação 31

4.1 Métricas de Recuperação
4.2 Métricas de Avaliação
4.3 Exercícios

Bibliografia 38

Artigos
Livros

1. Introdução à Recuperação da Informação

Recuperação da informação (RI) é o processo de recuperar documentos de uma coleção em resposta a uma consulta (ou requisição de busca) do usuário para atender sua necessidade de informação. Primeiro, é importante entender a diferença entre dados estruturados e dados não-estruturados. Vejamos a tabela Casa e seus atributos na Figura 1.1:

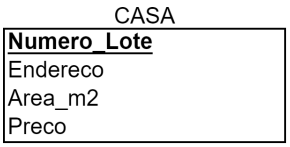


Figura 1.1: Exemplo de dados estruturados: Tabela Casa

Esse é um exemplo de **dados estruturados**. Pode-se comparar essa relação com contratos de venda de casas, que são exemplos de dados **não-estruturados**. Esses documentos variam de imobiliária para imobiliária, tem um conjunto de cláusulas que também varia de contrato para contrato e pode incluir dados de financiamento, fotos do imóvel etc. Por **informação não-estruturada**, entende-se informação que não tem um modelo formal bem definido nem uma linguagem formal para representação e processamento, mas é baseada na linguagem natural [2].

Com o advento da *World Wide Web*, o volume de informação não-estruturada em páginas Web, imagens, vídeos, documentos, etc compartilhados na rede cresceu de forma absurda. A recuperação da informação lida com problemas de armazenamento, indexação e recuperação (busca) dessas informações para satisfazer as necessidades do usuário. Esse problema se caracteriza um grande desafio pois o número de páginas Web e de conteúdo na rede vem crescendo a uma taxa fenomenal [2].

Esse campo de estudo é ainda mais antigo que o estudo de banco de dados. Nos tempos antigos a recuperação da informação lidava da recuperação de informação catalogada em bibliotecas baseada nos títulos, autores, tópicos e palavras-chave, que era buscados de forma manual. Informação, no contexto da RI, não requer estruturas interpretáveis por máquinas como nos sistemas de bancos de dados relacionais. Exemplos desse tipo de informação incluem: textos, documentos, livros, páginas

Web, emails, mensagens instantâneas e coleções de bibliotecas digitais. Logo, toda informação representada vagamente ou semi-estruturada faz parte do contexto da recuperação da informação.

1.1 Tipos de Sistemas de Recuperação da Informação

Um sistema de recuperação da informação pode ser caracterizado em diferentes níveis: pelos tipos de usuários, tipos de dados e pelos tipos de necessidade de informação, juntamente com o tamanho e escala do repositório de informação que ele manipula. Essas características são brevemente descritas a seguir [2]:

Tipos de Usuários Usuários podem variar de acordo com sua habilidade para interagir com sistemas computacionais. O usuário pode ser um **especialista** (por exemplo um bibliotecário) que está buscando por uma informação que está clara em sua mente e entende o escopo e a estrutura do repositório disponível ou um **leigo**, com uma necessidade de informação genérica, como por exemplo uma pessoa buscando roupas para comprar online.

Tipos de Dados Sistemas de busca podem ser planejados para tipos específicos de dados. Por exemplo, o problema de recuperar informação de roupas em uma loja online pode ser manipulado mais eficientemente por sistemas de consulta customizados que permitem filtrar por gênero, tipo e cor. Esse repositório de informação poderia ser **organizado hierarquicamente** baseado em um conceito ou hierarquia de tópicos.

Tipos de Necessidade de Informação A necessidade de informação pode ser classificada como navegacional, informacional ou transacional. Pesquisa **navegacional** se refere a encontrar uma informação particular que o usuário precisa rapidamente (como o site Web do professor George). O propósito da busca **informacional** é encontrar informação sobre um determinado tópico, por exemplo os artigos publicados pelo professor George nos últimos 5 anos. Já a pesquisa **transacional** tem como objetivo alcançar um site onde interação adicional irá ocorrer, como por exemplo comprar o livro de Banco de Dados do professor George.

A informação consome a atenção de seus receptores. Assim, a riqueza de informação cria uma pobreza de atenção e uma necessidade de alocar a atenção de forma eficiente dentre as abundantes fontes de informação [9]. Essa abundância de fontes de informação cria um alto ruído nos sistemas de RI, especialmente na Web, onde bilhões de páginas são indexadas. Sistemas de recuperação da informação são construídos com algoritmos eficientes e escaláveis para busca, indexação e priorização de resultados de consultas.

Mecanismos de recuperação da informação podem ser limitados a um coleção mais específica de documentos, como os **sistemas de busca empresariais** que usualmente oferecem soluções de RI para diferentes entidades em uma intranet corporativa, cujas entidades pesquisáveis incluem e-mails, manuais, documentos corporativos, bem como relatórios relacionando pessoas, reuniões e projetos.

1.2 Modelos de Interação em RI

Tipicamente a coleção de documentos contém dados não-estruturados. Outros tipos de documentos incluem imagens, áudios, vídeos e mapas. Os dados podem estar espalhados não-uniformemente nesses documentos sem estrutura alguma. Uma **consulta** é um conjunto de **termos** (também referidos como **palavras-chave**) inseridos pelo usuário para especificar uma necessidade de informação. Por exemplo, um usuário pode fazer uma consulta com as palavras-chave “Banco da Dados"na base de dados do Google Scholar[1]. Uma requisição informacional pode também ser uma frase em linguagem natural, por exemplo “Quem foi o campeão brasileiro de futebol em 2014?", ou “Encontre restaurantes de comida japonesa em Ipatinga."

[1] `https://scholar.google.com/`

Há dois modos principais de interação com sistemas de recuperação de informação - recuperação e navegação - os quais são alcançados através de diferentes tarefas de interação. **Recuperação** está relacionado com a extração de informação relevante de um repositório de documentos através de uma consulta RI para um propósito específico, por exemplo recuperar a última tese defendida na UFOP sobre Engenharia de Software. Já **navegação** está ligada à atividade exploratória de um usuário visitando ou navegando sobre documentos similares ou relacionados baseado na relevância ao usuário.

Durante a navegação, a necessidade de informação do usuário pode não ser definida *a priori* e ser flexível. Por exemplo, um usuário busca por “Ouro Preto"como palavra-chave. O sistema de recuperação de informação recupera os links para documentos relevantes contendo vários aspectos sobre Ouro Preto ao usuário. Esse usuário encontra o termo “Universidade Federal de Ouro Preto"em um dos documentos retornados e usa alguma forma de acesso (como clicar no link) e visita o documento sobre a universidade. Posteriormente, o usuário encontra uma entrada para “Festival de Inverno"que leva a informações sobre esse evento que o usuário se mostra bastante interessado. A atividade desse usuário é classificada como navegação. **Textos âncora** são as frases textuais usadas para rotular ***hiperlinks***, que são usados para a navegação.

A **busca na Web** combina ambos aspectos - navegação e recuperação - a é uma das principais aplicações da recuperação da informação atualmente, onde as páginas Web são análogas aos documentos. Mecanismos de busca na Web mantêm um repositório indexado das páginas Web. Esses mecanismos recuperam as páginas Web mais relevantes para o usuário em resposta a uma consulta (através de palavras-chave) com um ranqueamento decrescente de relevância. Esses aspectos serão abordados em maior profundidade ao longo desse curso.

1.3 Visão Geral de Recuperação da Informação

Nessa seção será apresentada uma visão de alto nível da arquitetura de um sistema de recuperação de informação. Além disso, serão apresentados os processos de recuperação e de ranqueamento de documentos em resposta a uma consulta do usuário.

1.3.1 Arquitetura de um Sistema de RI

A Figura 1.2 apresenta uma descrição simples e genérica da arquitetura de software de um sistema de RI. O primeiro passo na instalação de um sistema de RI é obter a coleção de documentos, que pode ser particular ou coletada a partir da Web. No segundo caso, um módulo **coletor** é responsável pela obtenção dos documentos. A coleção de documentos é armazenada em um disco usualmente chamado de **repositório central**. Os documentos no repositório central precisam ser indexados para que a recuperação e o ranqueamento sejam efetuados eficientemente. A estrutura de índice mais utilizada é o **índice invertido**, composto por todas as palavras distintas da coleção e, para cada palavra, a lista dos documentos que a contém [1].

Dado que a coleção de documentos está indexada, o processo de recuperação pode ser iniciado. O processo de recuperação consiste em retornar documentos que satisfaçam a uma consulta do usuário ou um clique em um hiperlink. No primeiro caso, dizemos que o usuário está **buscando** por informações de interesse. No segundo caso, dizemos que o usuário está **navegando** [1].

Para realizar uma busca, o usuário primeiro especifica uma **consulta** que reflete sua necessidade de informação. Na sequência, a consulta é analisada e sintaticamente expandida com, por exemplo, formas variantes das palavras da consulta. A consulta expandida, chamada **consulta do sistema**, é então processada, utilizando-se o índice para recuperar um subconjunto dos documentos. A seguir, os documentos recuperados são ranqueados e aqueles no topo do ranking são retornados ao usuário [1].

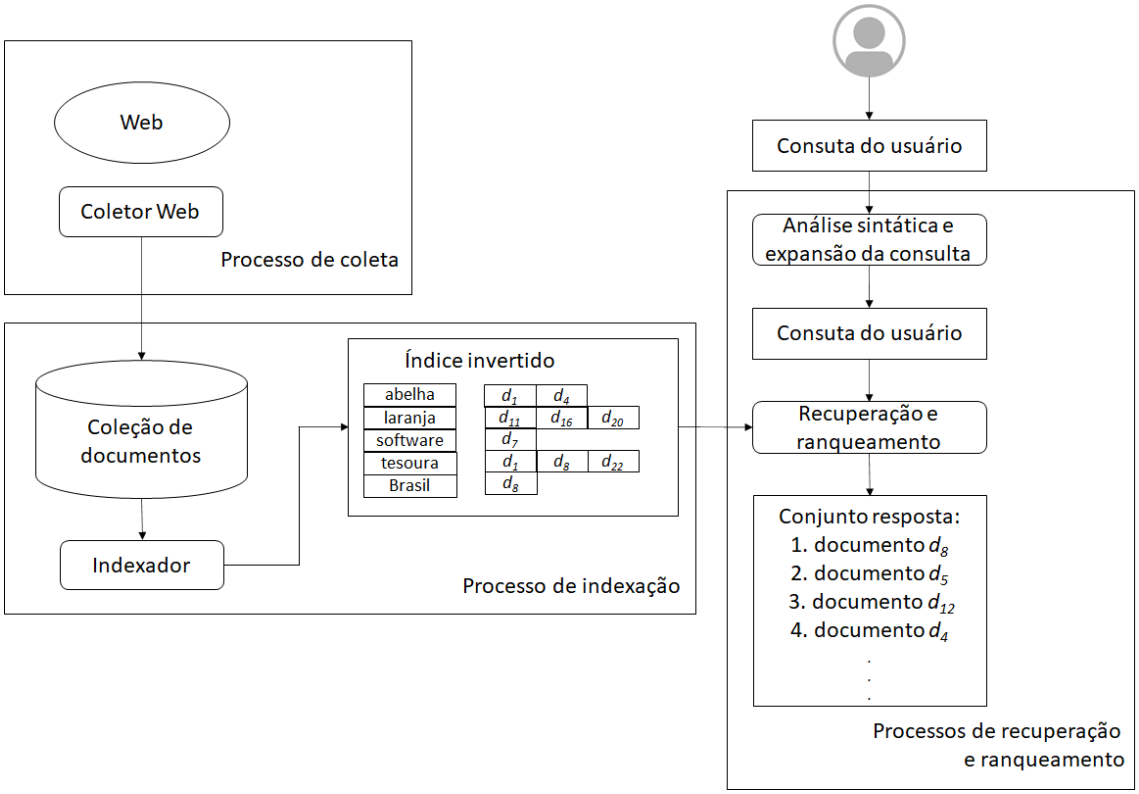


Figura 1.2: Arquitetura de alto nível de software de um sistema de RI [1].

1.3.2 Processo de Recuperação e de Ranqueamento

A Figura 1.3 apresenta uma visão mais aprofundada sobre os processos de recuperação e ranqueamento apresentados na Figura 1.2. Sobre os documentos da coleção é feito um conjunto de procedimentos de pré-processamento, como eliminação de *stopwords*, radicalização (*steeming*) e a seleção de um subconjunto de termos para serem utilizados como termos de indexação. Os termos de indexação são utilizados para compor a representação do documento, que pode ser menor do que o documento original dependendo do subconjunto de termos de indexação selecionado [1].

Com base nas representações dos documentos, é necessário criar um índice no texto. A estrutura mais utilizada para tal é o índice invertido. Uma alternativa para indexação dos documentos é a matriz de termos. As etapas necessárias à geração do índice compõem o **processo de indexação** e devem ser executadas offline, antes que o sistema esteja pronto para receber quaisquer consulta [1]. O Capítulo 2 apresentará as principais técnicas de pré-processamento e indexação de documentos.

Com a coleção de documentos foi indexada, o processo de recuperação pode ser iniciado. O usuário primeiro especifica uma **consulta** que reflete a sua necessidade de informação. Essa consulta é então pré-processada e modificada por operações similares às aplicadas na coleção de documentos. Operações típicas incluem a correção ortográfica e a eliminação de *stopwords*. A seguir, a consulta transformada é expandida e modificada. Por exemplo, a consulta pode ser modificada usando sugestões de consultas já feitas no sistema e confirmadas pelo usuário. No mecanismo de busca do Google temos como exemplo o campo “Em vez disso, pesquisar por ..."como sugestão para expansão de uma consulta [1].

A consulta expandida e modificada é então processada a fim de obter o conjunto de **documentos recuperados**, que é composto por documentos que contêm os termos da consulta. As etapas necessárias para a produção do conjunto de documentos recuperados constituem o **processo de recuperação** e podem ser feitas através de uma variedade de modelos [1]. Alguns modelos de

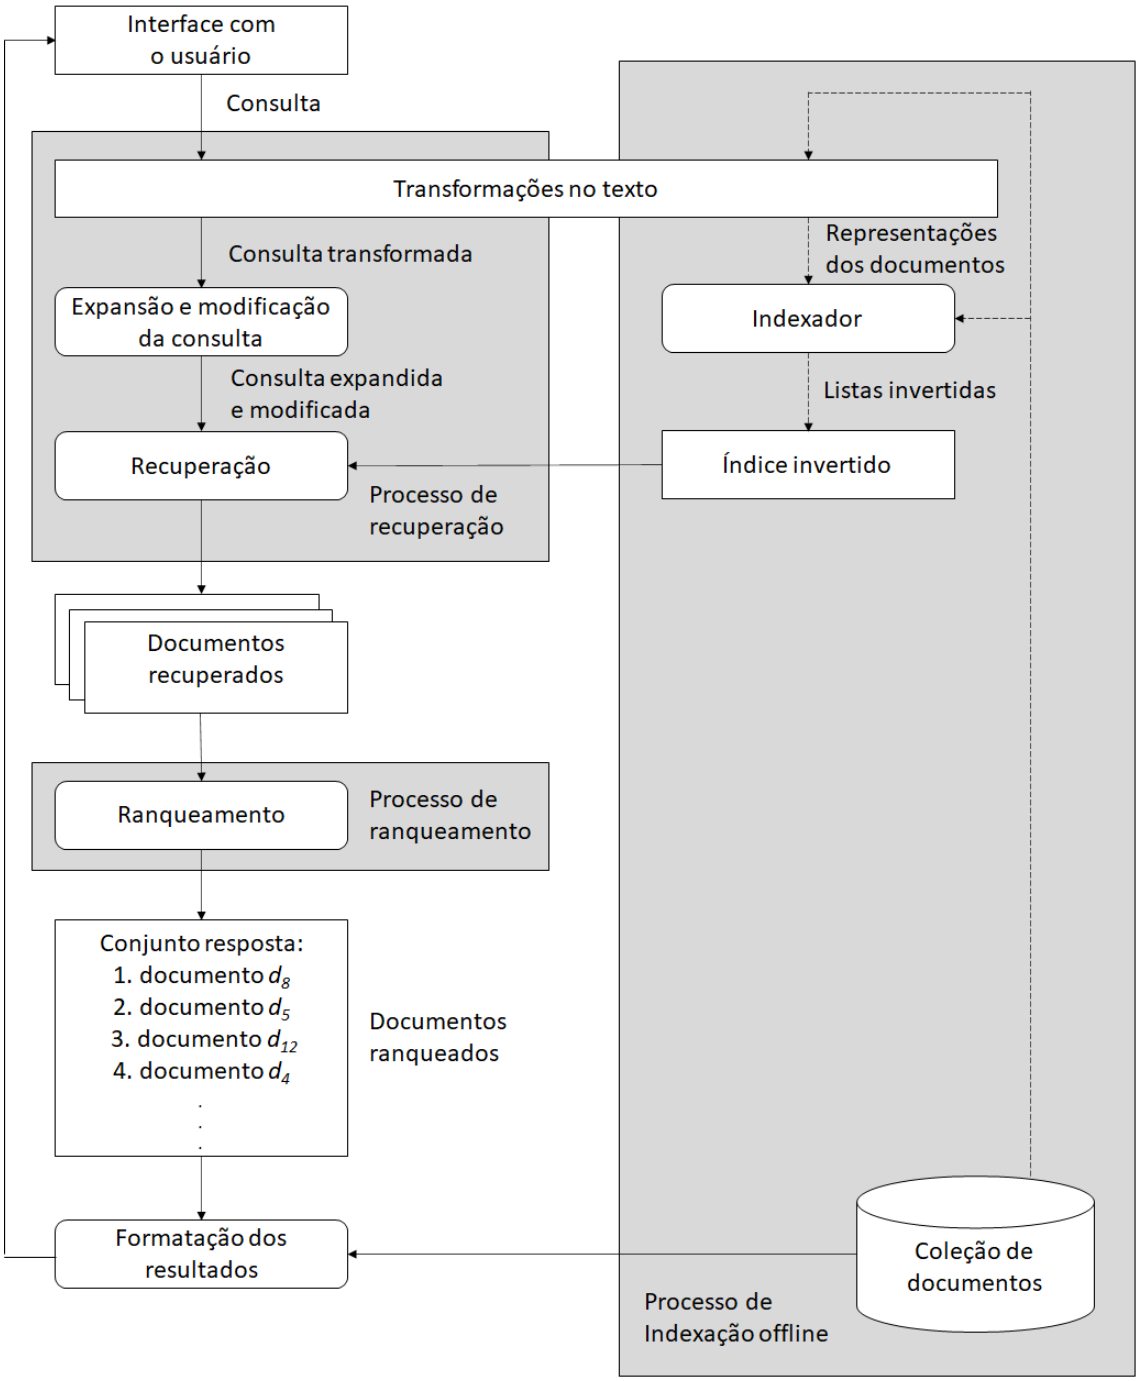


Figura 1.3: Detalhamento dos processos de indexação, recuperação e ranqueamento de documentos [1].

recuperação tradicionais serão apresentados no Capítulo 3.

A seguir, os documentos recuperados são ranqueados de acordo com a **probabilidade** de relevância para o usuário. Essa etapa é crítica, pois a qualidade do resultado percebida pelo usuário é essencialmente dependente do ranqueamento. Os documentos no topo do ranking são então formatados e apresentados ao usuário. A formatação consiste em recuperar o título dos documentos e gerar trechos de texto que contenham os termos da consulta feita pelo usuário [1].

1.4 Recuperação de Informação na Web

O surgimento da Web levou milhões de usuários a buscar informações que estão armazenadas em um número enorme de websites ativos. Para tornar essa informação acessível, mecanismos de busca como Google, Bing e Yahoo! devem rastrear e indexar esses sites e coleções de documentos em suas bases de dados de indexação. Adicionalmente, mecanismos de busca devem atualizar seus índices regularmente devido à natureza dinâmica da Web, onde novas páginas são criadas e alteradas constantemente. Dado que há milhões de páginas Web disponíveis na Web em variados tópicos, os mecanismos de busca precisam aplicar técnicas sofisticadas, além das técnicas de recuperação de informação clássica para identificar a relevância das páginas [2].

Como mencionado anteriormente, a Web é organizada numa estrutura de hyperlinks, onde um hyperlink é uma referência clicável para o endereço de uma outra página Web. O objetivo da análise da estrutura da Web é gerar uma representação estrutural sobre um website e páginas Web. A análise da estrutura da Web foca na estrutura interna dos documentos e lida com a estrutura de ligação usando hiperlinks no nível inter-documento. A estrutura e o conteúdo de páginas Web são combinadas por mecanismos de busca na Web para a recuperação de informação. Dada uma coleção de documentos Web interconectados, fatos interessantes e informativos descrevendo sua conectividade nesse subconjunto da Web podem ser descobertos. A análise da estrutura da Web também é usada para auxiliar na navegação e tornar possível a comparação/integração com diferentes esquemas de páginas Web. Esse aspecto da estrutura da Web facilita a classificação e clusterização de documentos Web [2].

1.4.1 Algoritmo Page Rank

No contexto da Web deve-se considerar, além da compatibilidade do documento Web com os termos da consulta, a autoridade do documento Web em questão. Por exemplo, para a maioria dos usuários é mais interessante ver os resultados da apuração de votos para presidente dos Estados Unidos num grande portal de notícias, como `g1.com` ou `r7.com`, do que em um pequeno blog pessoal devido à autoridade dessas páginas.

A autoridade de uma página é medida de forma automática pelos navegadores Web. O Google usa o conhecido algoritmo PageRank para tal [4], que é baseado na importância (autoridade) de cada página. Cada página Web tem um número de links de saída e links de entrada. É muito difícil determinar todos os links de entrada para uma página Web, enquanto que é relativamente fácil identificar os links de saída - basta buscar os links no conteúdo dos documentos. De acordo com o algoritmo PageRank, páginas que recebem um grande número de links de entrada são mais importantes do que páginas com poucos links. Entretanto, nem todos os links de entrada são importantes. Um link de entrada para uma página a partir de outra página com alto nível de importância é mais relevante do que o link de entrada de alguma página arbitrária. Assim, uma página tem um rank (ou importância) alto se a soma dos ranks das páginas que têm links de entrada para ela são altos [2].

A computação do ranqueamento de páginas segue uma abordagem iterativa. O PageRank de uma página Web é calculado como a soma de todos os pageranks das páginas Web com link de entrada para ela. O algoritmo trata a Web como um modelo de Markov. Uma rede imaginária recebe

visitas de uma sequência infinita de páginas por cliques aleatórios. O PageRank é uma estimativa do quão frequentemente um navegador chega a uma página em particular clicando aleatoriamente [2]. Formalmente, seja $P(x)$ o PageRank de uma página x, $C(x)$ o número de links de saída a partir de x e d, $0 < d < 1$ um fator de ajuste. O PageRank de uma página x pode ser calculado como:

$$P(x) = (1-d) + d \sum_{t \in T} \frac{P(t)}{C(t)} \tag{1.1}$$

onde T é o conjunto de páginas que têm link apontando para a página x. Assim, o PageRank é uma medida de importância independente-de-consulta de uma página Web. Essa medida da importância pode então ser combinada com as medidas de similaridade entre documentos e consultas para gerar um ranqueamento final das páginas Web em resposta a uma consulta.

1.5 Exercícios

Exercicio 1.1 Defina e dê exemplos de dados estruturados e dados não-estruturados. ■

Exercicio 1.2 Apresente e discuta os motivos pelos quais é difícil um novo mecanismo de busca na Web fazer frente como concorrente ao mecanismo de busca do Google. ■

Exercicio 1.3 Algoritmos de recuperação da informação na Web levam em consideração o texto contido nos documentos, sejam páginas Web, descrição de aplicativos, legendas de fotos em redes sociais, etc. Porém para uma melhor recuperação diversos outros fatores podem ser considerados. Quais fatores você consideraria, além do título e da descrição textual, para o ranqueamento num sistema de recuperação de informação para aplicativos da PlayStore? ■

2. Indexação e Pré-processamento

Sistemas de RI usualmente adoram termos de indexação para indexar e recuperar documentos. Um **termo de indexação** consiste de uma palavra ou um grupo de palavras consecutivas em um documento. De uma forma geral, um termo de indexação pode ser qualquer palavra que apareça no texto de um documento da coleção. Usualmente *stopwords* como artigos, preposições, adjetivos e advérbios não são considerados termos de indexação pois não trazem informação relevante para auxiliar na recuperação. Sistemas de RI comumente também agrupam sinônimos em um mesmo termo de indexação.

Considere ainda t como o número de termos de indexação na coleção de documentos D e k_i com um termo de indexação genérico. $V = \{k_1, ..., k_t\}$ é o conjunto de todos os termos de indexação distintos na coleção e é conhecido como **vocabulário** V da coleção. O tamanho do vocabulário é t. Para ilustrar os conceitos de indexação e pré-processamento de documentos considere o pequeno conjunto com quadro documentos dado na Figura 2.1 como exemplo.

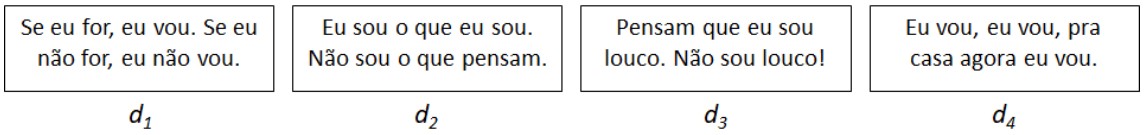


Figura 2.1: Coleção de exemplo composta por quatro documentos.

Nesse exemplo temos quatro documentos, $D = \{d_1, d_2, d_3, d_4\}$ e treze termos de indexação ($t = 13$) no vocabulário $V = \{$"se", "eu", "for", "vou", "não", "sou", "o", "que", "pensam", "louco", "pra", "casa", "agora"$\}$. Veremos na próxima seção como representar esses documentos computacionalmente e como processar as frequências dos termos de indexação.

2.1 Representação dos Documentos

2.1.1 Matriz de Termos

A ocorrência de um termo em um documento estabelece uma relação entre eles. Essas relações entre termos e documentos podem ser quantificadas, por exemplo, pela frequência do termo no documento. Essa relação pode ser escrita como uma **matriz de termos** $M = D \times t$:

$$M = \begin{array}{c} \\ k_1 \\ k_2 \\ k_3 \end{array} \begin{array}{c} \begin{array}{cc} d_1 & d_2 \end{array} \\ \begin{bmatrix} f_{1,1} & f_{1,2} \\ f_{2,1} & f_{2,2} \\ f_{3,1} & f_{3,2} \end{bmatrix} \end{array} \tag{2.1}$$

onde cada elemento $f_{i,j}$ representa a frequência do termo k_i no documento d_j. Usar a frequência de ocorrências para quantificar a relação entre termos e documentos fornece mais informação do que simplesmente registrar se o termo está presente ou não em um documento. Para ilustrar, a Tabela 2.1 apresenta a matriz de termos que representa a coleção de documentos dada na Figura 2.1.

Palavra	d_1	d_2	d_3	d_4
se	2	0	0	0
eu	4	2	1	3
for	2	0	0	0
vou	2	0	0	3
não	2	1	1	0
sou	0	3	2	0
o	0	2	0	0
que	0	2	1	0
pensam	0	1	1	0
louco	0	0	2	0
pra	0	0	0	1
casa	0	0	0	1
agora	0	0	0	1

Tabela 2.1: Representação da coleção da Figura 2.1 através de uma matriz de termos.

2.1.2 Índice Invertido

A matriz de termos é a forma mais simples de representar o número de ocorrências de palavras em uma coleção de documentos. Todavia, essa matriz requer $D \times t$ posições de memória para seu armazenamento. Em coleções reais e na recuperação de informação na Web é comumente inviável dispor de memória para armazenar essa estrutura.

Como alternativa, o índice invertido faz uso mais eficiente da memória para computar a relação de ocorrências em documentos. Em um índice invertido, cada palavra compõe um índice, que por sua vez possui uma lista dos documentos nos quais essa palavra ocorre e o número de ocorrências em cada documento. A Tabela 2.2 apresenta a estrutura de índice invertido correspondente para a representação da coleção de documentos contida na Figura 2.1, onde cada posição de um índice é expressa pelo par [documento, ocorrências].

Palavra	Índice invertido
se	$[d_1, 2]$
eu	$[d_1, 4]$, $[d_2, 2]$, $[d_3, 1]$, $[d_4, 3]$
for	$[d_1, 2]$
vou	$[d_1, 2]$, $[d_4, 3]$
não	$[d_1, 2]$, $[d_2, 1]$, $[d_3, 1]$
sou	$[d_2, 3]$, $[d_3, 2]$
o	$[d_2, 2]$
que	$[d_2, 2]$, $[d_3, 1]$
pensam	$[d_2, 1]$, $[d_3, 1]$
louco	$[d_3, 2]$
pra	$[d_4, 1]$
casa	$[d_4, 1]$
agora	$[d_4, 1]$

Tabela 2.2: Representação da coleção da Figura 2.1 através de índice invertido.

2.2 Visão Lógica dos Documentos

Em computadores modernos é possível representar um documento por meio do conjunto completo de palavras que os compõe. Nesse caso, dizemos que o sistema de RI adota uma **visão lógica *full-text*** (texto completo) dos documentos. Entretanto, em coleções muito grandes, pode ser interessante, por razões de eficiência, reduzir o conjunto de palavras-chave representativas. Isso pode ser feito eliminando-se as *stopwords* (como artigos e preposições), aplicando-se *stemming* (reduz palavras distintas a sua raiz gramatical comum) e identificando-se os grupos de substantivos (o que elimina adjetivos, advérbios e verbos). Essas transformações reduzem a complexidade da representação dos documentos e permitem mudar a representação de *full-text* para a de um conjunto de termos de indexação [1]. Várias visões lógicas intermediárias dos documentos podem ser adotadas por um sistema de RI, conforme apresentado na Figura 2.2.

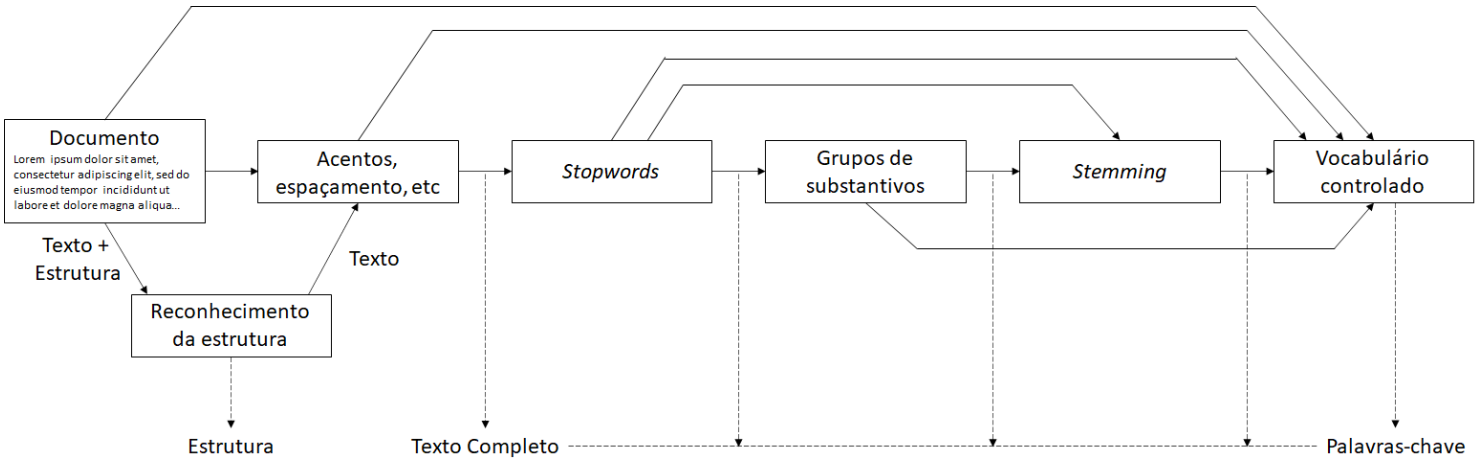


Figura 2.2: Visão Lógica de um documento: do texto completo ao conjunto de palavras-chave (termos de indexação) [1].

2.3 Pré-processamento de Texto

Nessa seção serão apresentados mais detalhes sobre as técnicas de pré-processamento de texto presentes na Figura 2.2.

2.3.1 Remoção de *Stopwords*

Stopwords (ou palavras de ordem) são palavras muito utilizadas em uma linguagem e que têm papel essencial na construção das sentenças, porém raramente contribuem para o significado da sentença. Palavras que ocorrem em 80% ou mais dos documentos são tipicamente consideradas como *stopwords* e são potencialmente consideradas inúteis à recuperação. Por causa da frequência e função dessas palavras, elas não contribuem muito para a relevância de um documento em uma consulta. Exemplos incluem artigos: o, a, os, as, um, uma, isso, esse, essa; preposições: de, para, e, mas, sobre, ou, por; pronomes: eu, você, ele, ela, nós; advérbios: muito, mais, ontem, bem, mal; e ainda alguns verbos genéricos como ser, estar e dizer. Segundo um estudo sobre a língua inglesa, apenas seis palavras contam por 20% de todas as palavras em um texto e as cinquenta palavras mais frequentes compõem 40% de todos os textos [2].

A remoção de *stopwords* de um documento deve ocorrer antes da indexação. As consultas também devem ser preprocessadas para remoção de stopwords. A remoção dessas palavras reduz o tamanho de uma estrutura de indexação em aproximadamente 40%. Entretanto, pode impactar a recuperação de documentos se alguma *stopword* for parte essencial de uma consulta. No exemplo da Figura 2.1 a remoção de *stopwords* torna a consulta inapropriada, pois há de fato poucos termos de indexação. Ademais alguns modelos de recuperação ponderam a prioridade de um termo de acordo com sua frequência, dando automaticamente menos importância às *stopwords*.

2.3.2 *Steeming*

A raiz (ou *stem*) de uma palavra pode ser obtida removendo-se seus sufixos e pré-fixos. Por exemplo, a raiz “recuper"é a palavra raiz para “recuperação", “recuperar"e “recuperando". Esses prefixos e sufixos são muito comuns nas línguas portuguesa e inglesa para denotar verbos, tempos e formas plurais. ***Steeming*** reduz as diferentes formas que uma palavra é formada por inflexão e derivação a uma raiz comum [2].

Um algoritmo de steeming pode ser usado para reduzir qualquer palavra a sua raiz. O RSPL steemer[1] [6] é um algoritmo de steeming para língua portuguesa em 8 passos que pode ser incorporado a sistemas de recuperação da informação para documentos em português. Para a língua inglesa há diversas outras ferramentas. Usar steeming para o pré-processamento dos documentos e consultas resulta num decréscimo do tamanho da estrutura de indexação e aumento da quantia de documentos recuperados, porém pode ter uma perda na precisão e na percepção de qualidade pelo usuário [2].

2.3.3 Vocabulário Controlado

Um tesauro (ou **vocabulário controlado**) comprime um lista pré-definida de conceitos importantes e das palavras que descrevem cada conceito para um domínio do conhecimento em específico. Para cada conceito na lista, um conjunto de sinônimos e palavras relacionadas também é compilado. Assim, um sinônimo pode ser convertido para seu conceito correspondente durante uma consulta. Esse passo de pré-processamento auxilia a prover um vocabulário padrão para indexação e busca. O uso de um tesauro, também conhecido como **coleção de sinônimos**, tem impacto substancial na revocação em sistemas de recuperação da informação [2]. Esse processo pode ser complicado pois uma mesma palavra pode ter diferentes significados em diferentes contextos, como “ponto", que pode ser do placar de uma partida de vôlei, uma parada de ônibus, ou ainda fazer parte de sutura de um corte.

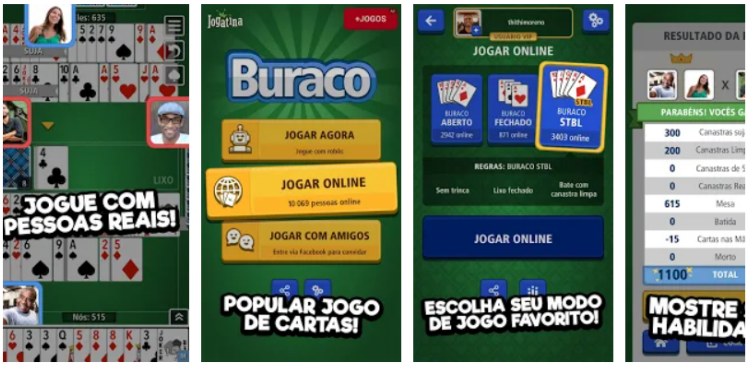
[1] `http://www.inf.ufrgs.br/~viviane/rslp/index.htm`

2.3.4 Acentos, dígitos, hifens e sinais de pontuação

Dígitos, datas, números de telefone, endereços de e-mail, URLs e outros tipos padrão de texto podem ou não ser removidos durante a fase de pré-processamento. Hifens e sinais de pontuação podem ser manipulados de diferentes formas. Ou a frase inteira com os hifens e/ou sinais de pontuação pode ser usada, ou ela pode ser removida. Em alguns sistemas, os caracteres representando os hifens ou sinais de pontuação podem ser removidos ou simplesmente substituídos por um espaço. Lidar com hifens automaticamente pode ser complexo, pois muitos termos específicos de um domínio como catálogo de produtos, versões diferentes de um elemento e outros podem ter hifens que são essenciais para identificá-los [2]. Para coleções genéricas usualmente é inviável enumerar os termos compostos com hifens que devem ou não ser mantidos como um termo único. Logo usualmente se considera o termo com hífen como uma palavra só. Como exemplo, considere o termo “guarda-chuva". Separadas as palavras “guarda"e “chuva"têm significados distintos da palavra composta “guarda-chuva"e, provavelmente, não levam aos mesmos documentos de interesse.

2.4 Exercícios

Exercicio 2.1 Considerando que a imagem abaixo apresenta o texto e capturas de tela de um documento que descreve um aplicativo de jogo de cartas, apresente quais termos são adequados como termos de indexação. Apresente ainda, para cada termo, sua frequência de termo ($f_{i,j}$) nesse documento.



Buraco, também conhecido como Biriba e Canastra, é o jogo de cartas mais tradicional do Brasil! No **Buraco Jogatina**, você pode jogar o popular jogo de baralho no seu celular, de graça e com um conjunto de regras de sua preferência: Buraco Aberto, Fechado ou STBL (Sem Trinca Bate Limpo). Feche mesas com 2 ou 4 jogadores e mande ver nas canastras jogando contra pessoas de carne e osso online, contra seus amigos e parentes e contra os robôs.

Exercicio 2.2 Considere a coleção de documentos apresentada na figura abaixo e exiba sua representação computacional por matriz de termos e por índice invertido.

Ai se eu te pego, ai, ai se eu te pego.	Aí eu bebo, aí eu bebo! Bebo pra carai!	Só eu que bebo? Será que só eu que bebo.	Ai, ai, ai, ai esse amor, é bom demais
d_1	d_2	d_3	d_4

■

3. Modelagem em RI

Modelagem em RI é um processo complexo cujo objetivo é produzir uma função de ranqueamento, ou seja, uma função que atribui escores a documentos com relação a uma consulta. Esse processo pode ser dividido em duas tarefas principais: (i) a criação de um arcabouço para representar documentos e consultas; e (ii) a definição de uma função de ranqueamento que calcula o grau de similaridade de cada documento com relação a uma consulta dada [1].

3.1 Modelagem e Ranqueamento

Um desafio a qualquer sistema de RI é prever quais documentos os usuários irão considerar relevantes como resultado a uma consulta. Além disso há um grau de incerteza ou imprecisão devido ao fato de que dois usuários podem discordar sobre o que é e o que não é relevante. Para lidar com esse problema, sistemas de RI implementam um algoritmo preditivo que almeja aproximar-se da opinião de uma grande fração dos usuários com relação à relevância dos resultados de um consulta. Esse algoritmo de predição é essencialmente a **função de ranqueamento** utilizada para estabelecer uma ordenação dos documentos recuperados [1].

3.1.1 Caracterização de um Modelo de RI

Segundo Baeza-Yates e Ribeiro-Neto [1], um **modelo** de recuperação de informação é uma quádrupla $[D, Q, \mathscr{F}, R(q_i, d_j)]$ onde:

1. D é um conjunto composto por visões lógicas (ou representações) dos **documentos** da coleção.
2. Q é um conjunto composto por visões lógicas (ou representações) das necessidades de informação dos usuários. Essas representações são chamadas **consultas**.
3. $\mathscr{F}$ é um arcabouço para modelar as representações dos documentos, das consultas e de seus relacionamentos, como conjuntos e relações Booleanas, vetores e operações da álgebra linear ou espaços e distribuições de probabilidade.
4. $R(q_i, d_j)$ é uma função de ranqueamento que associa um número real à representação de uma consulta $q_i \in Q$ e à representação de um documento $d_j \in D$. Esse ranking define um ordenamento entre os documentos em relação à consulta q_i.

Para construir um modelo, primeiro é necessário pensar nas representações dos documentos e nas necessidades de informação do usuário. Com relação a um documento, a representação pode ser um subconjunto de todos os termos do documento, removendo-se as *stopwords* (como artigos e preposições) do texto. Já com relação à consulta, a representação pode ser, por exemplo, um superconjunto dos termos da consulta formado pela consulta original enriquecida com sinônimos. Dadas essas representações, o arcabouço $\mathscr{F}$ no qual elas podem ser modeladas deve ser concebido. Esse arcabouço fornece naturalmente um intuição para a construção da função de ranqueamento. Serão explorados nesse curso os modelos Booleano, vetorial e probabilístico como arcabouços para construção da função de ranqueamento. Por fim, a função de ranqueamento $R(q_i, d_j)$ atribui um grau de relevância ao documento d_j com relação à consulta q_i [1]. Esse processo é apresentado na Figura 3.1.

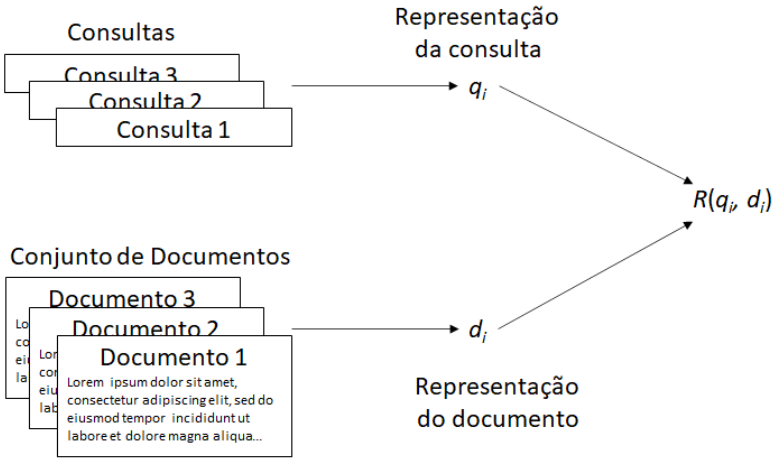


Figura 3.1: Visão Geral de Recuperação de Informação [1].

3.2 Modelo Booleano

Considere $V = \{k_1, k_2, ..., k_t\}$ como o vocabulário da coleção. Se três termos de indexação k_a, k_b e k_c ocorrem em um mesmo documento d_j, dizemos que o padrão $[k_a, k_b, k_c]$ de **coocorrência** de termos foi observado. Para um vocabulário V de tamanho t, o número total de padrões de coocorrência de termos nos documentos da coleção é 2^t. Como exemplo, o padrão $(1, 0, ..., 0)$ indica a presença do termo k_1 e nenhum outro. Já o padrão $(1, 1, ..., 1)$ indica a presença de todos os termos. Cada um desses padrões de coocorrências de termos é chamado de **componente conjuntivo de termo**. A um documento d_j, associa-se um componente conjuntivo de termo $c(q)$ que descreve quais termos ocorrem na consulta e quais não ocorrem. O componente conjuntivo de termo $c(d_j)$ fornece uma representação do documento d_j no sistema e o componente conjuntivo de termo $c(q)$ fornece uma representação da consulta q no sistema [1].

No **modelo Booleano**, os elementos da matriz de termos por documentos são 1, para indicar a presença do termo no documento; ou 0, para indicar a ausência do termo no documento. Uma consulta q é uma expressão Booleana sobre os termos da indexação, como, por exemplo: $[q = k_a \wedge (k_b \vee \neg k_c)]$. Dada uma consulta, um componente conjuntivo de termo que satisfaz suas condições é chamado de **componente conjuntivo de consulta** $c(q)$. Ao se compilar todos os componentes conjuntivos da consulta, pode-se reescrevê-la como uma disjunção desses componentes. Essa é conhecida como forma normal disjuntiva da consulta, referenciada como q_{DNF} [1].

Como exemplo, considere novamente a consulta $[q = k_a \wedge (k_b \vee \neg k_c)]$ e suponha que o vocabulário da coleção seja dado por $V = \{k_a, k_b, k_c\}$. A consulta q pode ser reescrita em forma normal

disjuntiva como:

$$q_{DNF} = (1,1,1) \vee (1,1,0) \vee (1,0,0) \tag{3.1}$$

Essa abordagem funciona mesmo que o vocabulário da coleção contenha termos que não estão na consulta. Suponha que o vocabulário do exemplo anterior seja dado por $V = \{k_a, k_b, k_c, k_d\}$. Então, um documento d_j que contenha apenas os termos k_a, k_b e k_c é representado pelo componente conjuntivo de termo $(1,1,1,0)$ e a consulta $[q = k_a \wedge (k_b \vee \neg k_c)]$ é representada na forma normal disjuntiva como:

$$\begin{aligned} q_{DNF} =& (1,1,1,0) \vee (1,1,1,1) \vee \\ & (1,1,0,0) \vee (1,1,0,1) \vee \\ & (1,0,0,0) \vee (1,0,0,1) \end{aligned} \tag{3.2}$$

Ou seja, o termo k_d é considerado ao mesmo tempo como ausente e presente em cada conjunto conjuntivo, uma vez que ele não foi especificado na consulta. Se o documento satisfaz as condições envolvendo os termos da consulta, então existe um componente conjuntivo da consulta que casa com o componente conjuntivo do documento, que nessa situação pode ou não conter k_d. Por simplicidade, podemos restringir a representação dos componentes conjuntivos aos termos que ocorrem explicitamente na consulta, conforme será feito adiante.

Considere $c(q)$ como qualquer dos componentes conjuntivos da consulta q. Dado um documento d_j, sendo $c(d_j)$ seu componente conjuntivo de documento correspondente, então a **similaridade** entre o documento d_j e a consulta q é dada por

$$sim(d_j, q) = \begin{cases} 1 & \text{se } \exists c(q) \mid c(q) = c(d_j) \\ 0 & \text{caso contrário} \end{cases} \tag{3.3}$$

Note que, no modelo Booleano, **não há satisfação parcial** das condições da consulta. Se $sim(d_j, q) = 1$, então o modelo prevê que o documento d_j seja relevante à consulta q; caso contrário a predição é de que d_j não seja relevante. Esse critério binário de decisão, sem nenhuma noção de grau, impede uma boa qualidade na recuperação. Além disso, com frequência não é possível traduzir uma necessidade de informação em uma expressão Booleana [1].

As principais **vantagens** do modelo Booleano são seu formalismo claro e sua simplicidade, com adoção de pesos binários para os termos de indexação. Por outro lado, como **desvantagens** temos o fato de não existir um ranqueamento, o que pode levar à recuperação de muitos documentos na verdade irrelevantes. Além disso, a formulação de consultas Booleanas é inconveniente para a maior parte dos usuários. Atualmente sabe-se que a ponderação dos termos de indexação pode levar a uma melhoria considerável na qualidade da recuperação, conforme discutido na próxima seção [1].

3.3 Ponderação de Termos

Dado um conjunto de termos de indexação para um documento, pode-se notar que nem todos os termos são igualmente importantes para descrever o conteúdo dos documentos. De fato, existem termos de indexação que são mais vagos do que outros. Como exemplo, considere uma colação sobre trabalhos de conclusão de curso de uma universidade com dez mil documentos. O termo "Trabalho de Conclusão de Curso"aparece em todos os documentos, logo não é útil como termo de indexação. Por outro lado, suponha que o termo "Ciência dos Dados"aparece em apenas cinco documentos. Certamente esse é um termo mais útil para a recuperação, pois reduz consideravelmente o número de documentos que podem ser de interesse do usuário.

A fim de caracterizar a importância dos termos, um **peso** $w_{i,j} > 0$ é associado a cada termo de indexação k_i de um documento d_j na coleção. Para um termo de indexação que não aparece em k_i, $w_{i,j} = 0$ [1]. Para contabilizar a importância dos termos de indexação, deve-se computar os pesos que refletem a importância do termo na coleção e em cada documento em particular. Esses pesos dependem das frequências de ocorrência dos termos nos documentos.

Seja $f_{i,j}$ a **frequência de ocorrência** do termo de indexação k_i no documento d_j, ou seja, o número de vezes que k_i aparece em d_j. A **frequência total** F_i do termo k_i na coleção é a soma das frequências de ocorrência do termo em todos os documentos:

$$F_i = \sum_{j=1}^{N} f_{i,j} \tag{3.4}$$

onde N é o número de documentos na coleção. A **frequência de documento** para um termo k_i é o número de documentos nos quais k_i ocorre e é indicado simplesmente como n_i. Observe que $n_i \leq F_i$.

3.3.1 Correlações entre Termos

Até então, os pesos dos termos de indexação tem sido considerados como mutualmente independentes. Isso significa que saber o peso $w_{i,j}$ associado ao par (k_i, d_j) não traz informação alguma a respeito do peso $w_{i+1,j}$ associado ao par k_{i+1,d_j}. Entretanto, usualmente as ocorrências dos termos de indexação nos documentos são correlacionadas. Considere, por exemplo, que os termos “dados"e “ciência"sejam utilizados para indexar um documento sobre Ciência dos Dados. Com frequência, nesse documento, a ocorrência de um desses termos atrai a ocorrência do outro. Assim, eles são correlacionados e seus pesos deveriam refletir tal correlação.

Seja $M = [m_{ij}]$ uma matriz de termos por documentos com t linhas e N colunas onde $m_{ij} = w_{i,j}$, ou seja, cada célula da matriz é dada pelo peso associado ao par termo-documento (k_i, d_j). Sendo M^T a matriz transposta de M, a matriz $C = M \times M^T$ é uma **matriz de correlação** entre termos. Cada elemento $c_{u,v} \in C$ expressa uma correlação entre os termos k_u e k_v, dada por:

$$c_{u,v} = \sum_{d_j \in D} w_{u,j} \times w_{v,j} \tag{3.5}$$

A matriz C de correlação entre termos estabelece um relacionamento entre quaisquer dois termos k_u e k_v baseado em suas coocorrências dentre de documentos da coleção D. Esse relacionamento é quantificado por um fator de correlação $c_{u,v}$. Quanto maior o número de documentos nos quais k_u e k_v ocorrem simultaneamente, maior será essa correlação. Além disso, é possível se aproveitar de fatores como a distância entre dois termos dentro dos documentos para melhorar as estimativas de correlação entre termos. A motivação é que termos que ocorrem próximos uns aos outros têm correlações mais fortes do que termos que ocorrem a uma grande distância. Essas estratégias mais elaboradas não serão abordadas nesse curso.

3.4 Ponderação TF-IDF

A Frequência do Termo (TF, *Term Frequency*) e a Frequência Inversa de Documento (IDF, *Inverse Document Frequency*) são os fundamentos do esquema de ponderação mais popular em RI, denominado TF-IDF.

3.4.1 Ponderação da Frequência de Termos

Segundo a Hipótese de Luhn [5], o valor ou peso de um termo k_i que ocorre em um documento d_j é simplesmente proporcional à frequência do termo $f_{i,j}$. Isto é, quanto mais frequentemente um termo k_i ocorrer no texto do documento d_j maior será a **frequência do termo** $TF_{i,j}$.

#	Termo	$f_{i,1}$	$f_{i,2}$	$f_{i,3}$	$f_{i,4}$	$TF_{i,1}$	$TF_{i,2}$	$TF_{i,3}$	$TF_{i,4}$
1	se	2	0	0	0	2,00	0,00	0,00	0,00
2	eu	4	2	1	3	3,00	2,00	1,00	2,58
3	for	2	0	0	0	2,00	0,00	0,00	0,00
4	vou	2	0	0	3	2,00	0,00	0,00	2,58
5	não	2	1	1	0	2,00	1,00	1,00	0,00
6	sou	0	3	2	0	0,00	2,58	2,00	0,00
7	o	0	2	0	0	0,00	2,00	0,00	0,00
8	que	0	2	1	0	0,00	2,00	1,00	0,00
9	pensam	0	1	1	0	0,00	1,00	1,00	0,00
10	louco	0	0	2	0	0,00	0,00	2,00	0,00
11	pra	0	0	0	1	0,00	0,00	0,00	1,00
12	casa	0	0	0	1	0,00	0,00	0,00	1,00
13	agora	0	0	0	1	0,00	0,00	0,00	1,00

Tabela 3.1: Vocabulários, frequências de termo e frequências de termo logarítmicas da coleção de documentos da Figura 2.1.

Essa hipótese baseia-se na observação que termos com alta frequência são importantes para descrever os tópicos-chave de um documento, a qual leva à seguinte formulação da ponderação TF:

$$tf_{i,j} = f_{i,j} \tag{3.6}$$

Uma variante da ponderação TF também frequentemente usada é

$$tf(i,j) = \begin{cases} 1 + \log f_{i,j} & \text{se } f_{ij} > 0 \\ 0 & \text{caso contrário} \end{cases} \tag{3.7}$$

onde o logaritmo usa base 2. A expressão com logaritmo será adotada adiante pois é a forma preferível para a ponderação TF e torna os pesos diretamente comparáveis aos pesos IDF, que serão apresentados posteriormente. Como exemplo, a Tabela 3.1 apresenta o vocabulário da coleção de documentos apresentada na Figura 2.1, bem como as frequências de cada termo em cada documento ($f_{i,j}$) e os valores logarítmicos de frequência de termos (TF).

3.4.2 Ponderação da Frequência Inversa de Documentos

Jones (1972) [3] desenvolveu uma interpretação estatística da especificidade dos termos, chamada IDF, que tornou-se a precursora ponderação de termos. O IDF se baseia nas noções de exaustividade e de especificidade dos termos do vocabulário. Exaustividade é uma propriedade das descrições dos documentos e especificidade é uma propriedade dos termos de indexação. A **exaustividade** da descrição de um documento é interpretada como a abrangência que ela provê para os tópicos principais do documento. A **especificidade** de um termo de indexação é interpretada como quão bem um termo descreve o tópico de um documento.

Se adicionarmos novos termos do vocabulário a um documento, a exaustividade da descrição do documento aumenta. Além disso, a probabilidade de que esse documento satisfaça a uma consulta também aumenta. De fato, quanto mais termos de indexação são atribuídos a um documento, mais exaustiva fica sua descrição. Sua probabilidade de recuperação em resposta a uma consulta aleatória também aumenta. Entretanto, se muitos termos estiverem presentes em um documento, ele será retornado mesmo para consultas para os quais não é relevante. Isso sugere que o número médio de termos de indexação por documento deve ser otimizado de modo que a probabilidade de relevância

de um documento recuperado seja maximizada. Esse número ótimo de termos de indexação define a **exaustividade ótima** para as descrições desses documentos.

A especificidade é uma propriedade da semântica do termo, que pode ser mais ou menos específico dependendo do seu significado. Para ilustrar, o termo “veículo"é menos específico que os termos “caminhão"e “carro". Logo, se a indexação fosse feita manualmente, é esperado que o termo “veículo"fosse usado para indexar mais documentos do que os termos “caminhão"e “carro". Entretanto, usualmente não é viável interpretar manualmente a especificidade de um tempo.

Uma alternativa a esse problema é considerar a especificidade como uma função da utilização dos termos. Logo, a **exaustividade estatística** da descrição de um documento pode ser quantificada como o número de termos de indexação que ele possui. Já a **especificidade estatística** de um termo é a função do inverso do número de documentos nos quais ele ocorre.

Naturalmente, se as descrições dos documentos ficarem mais longas, a especificidade dos termos tende a ficar mais baixa. Em específico, se um termo ocorre em todos os documentos da coleção sua especificidade é mínima e o termo não é útil para a recuperação. Esse raciocínio leva àa ideia da ponderação de termos por especificidade. Para isso, os pesos dos termos podem ser representados como uma função das frequências relativas dos termos. Considere um termo i, sua **Frequência Inversa de Documentos (IDF)** é:

$$IDF_i = \log \frac{N}{n_i} \tag{3.8}$$

onde n_i é o número de documentos nos quais o termo i ocorre e N é o número de documentos da coleção. Para ilustrar, a Tabela 3.2 apresenta os valores de IDF para cada um dos termos presentes nos documentos do exemplo da Figura 2.1.

#	Termo	n_i	$IDF_i = \log(N/n_i)$
1	se	1	2,00
2	eu	4	0,00
3	for	1	2,00
4	vou	2	1,00
5	não	3	0,42
6	sou	2	1,00
7	o	1	2,00
8	que	2	1,00
9	pensam	2	1,00
10	louco	1	2,00
11	pra	1	2,00
12	casa	1	2,00
13	agora	1	2,00

Tabela 3.2: Valores de IDF para os termos de indexação dos documentos presentes na Figura 2.1 ($N = 4$).

3.4.3 Ponderação TF-IDF

O esquema de ponderação de termos mais empregado em recuperação de informação é a **ponderação TF-IDF**, onde o peso $w_{i,j}$ do termo associado ao para (k_i, d_j) é dado por:

$$w_{i,j} = \begin{cases} (1 + \log f_{i,j}) \times \log \frac{N}{n_i} & \text{se } f_{i,j} > 0 \\ 0 & \text{caso contrário} \end{cases} \tag{3.9}$$

A Tabela 3.3 apresenta os valores de TF-IDF para a coleção de exemplo apresentada na Figura 2.1. Ainda que simplista, esse exemplo ilustra as propriedades do esquema de ponderação TF-IDF. Os termos mais raros, como “casa"e “for"têm pesos mais altos pois são mais seletivos. Além disso, os termos mais frequentes dentro de um documento possuem frequências relativas mais altas. Há diversas variantes das ponderações TF e IDF, porém, por questões de objetividade elas não serão abordadas nesse curso.

#	Termo	d_1	d_2	d_3	d_4
1	se	4,00	0,00	0,00	0,00
2	eu	0,00	0,00	0,00	0,00
3	for	4,00	0,00	0,00	0,00
4	vou	2,00	0,00	0,00	2,58
5	não	0,84	0,42	0,42	0,00
6	sou	0,00	2,58	2,00	0,00
7	o	0,00	4,00	0,00	0,00
8	que	0,00	2,00	1,00	0,00
9	pensam	0,00	1,00	1,00	0,00
10	louco	0,00	0,00	4,00	0,00
11	pra	0,00	0,00	0,00	2,00
12	casa	0,00	0,00	0,00	2,00
13	agora	0,00	0,00	0,00	2,00

Tabela 3.3: Valores de TF-IDF para a coleção de exemplo dada na Figura 2.1.

3.5 Normalização pelo Tamanho dos Documentos

Em uma coleção o tamanho dos documentos pode varia consideravelmente. Isso é problemático, pois documentos mais longos têm mais chances de serem recuperados em consulta simplesmente por ter mais palavras (e, consequentemente, termos de indexação). A fim de compensar esse efeito indesejado, podemos dividir o número de ordem de cada documento pelo seu tamanho - procedimento chamado de **normalização pelo tamanho dos documentos**. Essa normalização é amplamente adotada em sistemas de RI por usualmente leva a um ranqueamento melhor dos resultados de uma consulta.

As três formas mais usuais de normalização pelo tamanho dos documentos são:

Tamanho em Bytes é meramente o número de bytes que o documento ocupa em memória. Na maioria dos sistemas 1 caractere equivale a 1 byte.

Número de Palavras decompõe o documento em palavras e considera a contagem de palavras contidas nesse documento.

Norma do Vetor é dada pela raiz da somatória dos quadrados dos pesos de cada termo k_i no documento d_j:

$$|\vec{d}_j| = \sqrt{\sum_{i}^{t} w_{i,j}^2} \tag{3.10}$$

A Tabela 3.4 apresenta os valores dos documentos dados na Figura 2.1 conforme as três formas de normalização apresentadas.

Medida	d_1	d_2	d_3	d_4
Tamanho em bytes	45	42	39	28
Número de palavras	12	11	8	9
Norma do vetor	6,057	5,278	4,709	4,322

Tabela 3.4: Medidas de tamanho de documento para a coleção de documentos da Figura 2.1

3.6 Modelo Vetorial

O modelo vetorial reconhece que a recuperação Booleana é limitada e propõe um alternativa na qual casamentos parciais são possíveis. Isso é feito por meio de atribuição de pesos **não binários** aos termos de indexação das consultas e dos documentos, que, por sua vez, são usados para computar o **grau de similaridade** entre cada documento da coleção e uma determinada consulta. Ao se ordenar os documentos decrescentemente pela similaridade, o modelo vetorial considera documentos que casam parcialmente com os termos da consulta. De fato, documentos ranqueados fornecem uma resposta mais precisa (no sentido de satisfazer a necessidade de informação do usuário) do que o modelo Booleano.

Para o **modelo vetorial**, o peso $w_{i,j}$ associado ao par termo-documento (k_i, d_j) é não-negativo e não-binário. Os termos de indexação são representados por vetores unitários em um espaço com t dimensões, no qual t é o número de termos de indexação. As representações do documento d_j e da consulta q são vetores com t dimensões, dadas por:

$$\begin{aligned} \vec{d}_j &= (w_{1,j}, w_{2,j}, ..., w_{t,j}) \\ \vec{q} &= (w_{1,q}, w_{2,q}, ..., w_{t,q}) \end{aligned} \tag{3.11}$$

onde $w_{i,q}$ é o peso associado ao par termo-consulta (k_i, q), sendo $w_{i,q} \geq 0$.

Assim, um documento d_j e uma consulta de usuário q são representadas como vetores com t dimensões. O modelo vetorial então calcula o grau de similaridade do documento d_j com relação à consulta q sob a forma de correlação entre os vetores $\vec{d}_j$ e $\vec{q}$. Essa correlação pode ser quantificada, por exemplo, pelo cosseno do ângulo entre esses dois vetores:

$$\begin{aligned} sim(d_j, q) &= \frac{\vec{d}_j \bullet \vec{q}}{|\vec{d}_j| \times |\vec{q}|} \\ &= \frac{\sum_{i=1}^{t} w_{i,j} \times w_{i,q}}{\sqrt{\sum_{i=1}^{t} w_{i,j}^2} \times \sqrt{\sum_{i=1}^{t} w_{i,q}^2}} \end{aligned} \tag{3.12}$$

onde $|\vec{d}_j|$ e $|\vec{q}|$ são as normas dos vetores do documento e da consulta e $\vec{d}_j \bullet \vec{q}$ é o produto interno dos dois vetores. O fator $|\vec{q}|$ não afeta o ranqueamento uma vez que é o mesmo para todos os documentos. Já fator $|\vec{d}_j|$ faz a normalização pelo tamanho do documento.

Os pesos adotados no modelo vetorial são aqueles obtidos pelo TF-IDF apresentado anteriormente, assim temos:

$$\begin{aligned} w_{i,q} &= (1 + \log f_{i,q}) \times \log \left(\frac{N}{n_i}\right) \\ w_{i,j} &= (1 + \log f_{i,j}) \times \log \left(\frac{N}{n_i}\right) \end{aligned} \tag{3.13}$$

onde $f_{i,q}$ é a frequência do termo k_i no texto da consulta q. Como $w_{i,j} \geq 0$ e $w_{i,q} \geq 0$, $sim(d_j, q)$ varia entre 0 e 1. Assim, em vez de adotar um critério de decisão binário, o modelo vetorial ordena os documentos de acordo com o grau de similaridade com relação a uma dada consulta. Um

documento pode ser recuperado mesmo que satisfaça apenas parcialmente a uma consulta. Dessa forma, pode-se inclusive definir um limiar para o grau de similaridade $sim(d_j, q)$ e recuperar apenas documentos com similaridade maior que esse limiar.

A Tabela 3.5 apresenta a computação do ranking para a coleção da Figura 2.1 em resposta à consulta “eu sou". Termos que não aparecem na consulta ($w_{i,q} = 0$) foram omitidos. Note que o documento d_2 é o mais bem ranqueado, pois trás o termo “sou"três vezes, e o documento d_3 é o segundo mais bem ranqueado, pois tem o termo “sou"duas vezes. O termo “eu"está presente em todos os documentos, logo sua relevância para recuperação é nula ($w_{i,q} = 0$).

Doc	Computação do Escore	Escore
d_1	$\frac{0{,}00\times0{,}00+0{,}00\times1{,}00}{6{,}057}$	$0{,}000$
d_2	$\frac{0{,}00\times0{,}00+2{,}58\times1{,}00}{5{,}278}$	$0{,}489$
d_2	$\frac{0{,}00\times0{,}00+2{,}00\times1{,}00}{4{,}709}$	$0{,}424$
d_2	$\frac{0{,}00\times0{,}00+0{,}00\times1{,}00}{4{,}322}$	$0{,}000$

Tabela 3.5: Cálculo da similaridade dos documentos da Figura 2.1 com relação à consulta “eu sou"no modelo vetorial (Equação 3.12).

As principais **vantagens** do modelo vetorial são: (i) seu esquema de ponderação de termos melhora a qualidade da recuperação; (ii) sua estratégia de casamento parcial permite a recuperação de documentos que se aproximam das condições da consulta; (iii) a fórmula do cosseno ordena os documentos de acordo com o grau de similaridade com relação à consulta; e (iv) a normalização pelo tamanho do documento está naturalmente embutida no modelo. Já sua **desvantagem** está no fato de considerar os termos de indexação como mutualmente independentes. Todavia, na prática, considerar as dependências entre os termos é desafiador e pode levar a resultados ruins se não foi feito adequadamente.

3.7 Modelo Probabilístico

O modelo probabilístico for proposto por [7]. A ideia principal desse modelo é de que, a partir de uma consulta do usuário, existe um conjunto de documentos que contém exatamente os documentos relevantes e nenhum outro. Esse conjunto é chamado conjunto de **resposta ideal**.

No modelo probabilístico, uma consulta q é um subconjunto dos termos de indexação. Um documento d_j é representado por um vetor de pesos binários que indicam a presença ou ausência de termos de indexação:

$$\vec{d}_j = (w_{1,j}, w_{2,j}, ..., w_{t,j}) \tag{3.14}$$

onde $w_{i,j} = 1$ se o termo k_i ocorre no documento d_j e 0 caso contrário. Seja R um conjunto de documentos estimados como relevantes para uma consulta q, e seja $\overline{R}$ o conjunto de documentos estimados como não relevantes (complemento de $\overline{R}$). $P(R|\vec{d}_j, q)$ é a probabilidade de que o documento d_j com a representação $\vec{d}_j$ seja relevante para a consulta q. Adicionalmente, $P(\overline{R}|\vec{d}_j, q)$ é a probabilidade de que o documento d_j não seja relevante para a consulta q. Dessa forma, a similaridade $sim(d_j, q)$ entre o documento d_j e a consulta q é dada por:

$$sim(d_j, q) = \frac{P(R|\vec{d}_j, q)}{P(\overline{R}|\vec{d}_j, q)} \tag{3.15}$$

Através da regra de Bayes temos:

$$sim(d_j,q) = \frac{P(\vec{d}_j|R,q) \times P(R,q)}{P(\vec{d}_j|\overline{R},q) \times P(\overline{R},q)} = \frac{P(\vec{d}_j|R,q) \times P(R|q)}{P(\vec{d}_j|\overline{R},q) \times P(\overline{R}|q)} \tag{3.16}$$

onde $P(\vec{d}_j|R,q)$ é a probabilidade de que um documento arbitrariamente selecionado do conjunto R de documentos relevantes para a consulta q terá a representação $\vec{d}_j$; e $P(R|q)$ é a probabilidade de que um documento selecionado aleatoriamente a partir de toda a coleção seja relevante para a consulta q. Os significados de $P(\vec{d}_j|\overline{R},q)$ e de $P(\overline{R}|q)$ são análogos e complementares [1].

Como $P(R|q)$ e $P(\overline{R}|q)$ são os mesmos para todos os documentos da coleção, temos que:

$$sim(d_j,q) \approx \frac{P(\vec{d}_j|R,q)}{P(\vec{d}_j|\overline{R},q)} \tag{3.17}$$

Dado que a representação do documento d_j é composta por valores binários que indicam se os termos estão presentes ou não no documento, e assumindo que os termos de indexação são independentes, obtemos:

$$sim(d_j,q) \approx \frac{(\prod_{k_i|w_{i,j}=1} P(k_i|R,q) \times (\prod_{k_i|w_{i,j}=0} P(\overline{k_i}|R,q))}{(\prod_{k_i|w_{i,j}=1} P(k_i|\overline{R},q) \times (\prod_{k_i|w_{i,j}=0} P(\overline{k_i}|\overline{R},q))} \tag{3.18}$$

onde $P(k_i|R,q)$ é a probabilidade de que o termo de indexação k_i esteja presente em um documento aleatoriamente selecionado a partir do conjunto R de documentos relevantes à consulta q, e $P(\overline{k_i}|R,q)$ é a probabilidade que o termo de indexação k_i não esteja presente em um documento aleatoriamente selecionado do conjunto R. As probabilidades associadas ao conjunto Rtêm significados análogos.

Através de transformações baseadas em logaritmos e produtórios da Equação 3.18, temos a **expressão-chave** para a computação do ranking no modelo probabilístico:

$$sim(d_j,q) \approx \sum_{k_i \in q \wedge k_i \in d_j} \log\left(\frac{P(k_i|R,q)}{1-P(k_i|R,q)}\right) + \log\left(\frac{P(k_i|\overline{R},q)}{1-P(k_i|\overline{R},q)}\right) \tag{3.19}$$

A princípio, a limitação desse modelo é que não conhecemos de antemão o conjunto R. Ademais, não é viável solicitar ao usuário que defina o conjunto R manualmente. Dessa forma, faz-se necessário definir um método para computar de forma autônoma as probabilidades $P(k_i|R,q)$ e $P(k_i|\overline{R},q)$. Algumas estratégias para tal serão apresentadas a seguir.

3.7.1 Tabela de Contingência das Incidências de Termos

Seja N o número de documentos da coleção, n_i o número de documentos que contêm o termo k_i, R o número total de documentos que atendem à consulta q e r_i o número de documentos relevantes que contêm o termo k_i, a **tabela de contingência das incidências de termos** é apresentada na Tabela 3.6.

Caso	Relevantes	Não relevantes	Total
Documentos que contêm k_i	r_i	$n_i - r_i$	n_i
Documentos que não contêm k_i	$R - r_i$	$N - n_i - (R - r_i)$	$N - n_i$
Todos os documentos	R	$N - R$	N

Tabela 3.6: Tabela de contingência das incidências de termos

Assumindo que a informação da tabela de contingência das incidências de termos está disponível para uma dada consulta (o que não é verdade pois não se tem informação sobre quais documentos são relevantes ou não para uma consulta), poderíamos escrever:

$$\begin{aligned} P(k_i|R,q) &= \frac{r_i}{R} \\ P(k_i|\overline{R},q) &= \frac{n_i - r_i}{N - R} \end{aligned} \tag{3.20}$$

e reescrever a Equação 3.19 como:

$$sim(d_j,q) \approx \sum_{k_i \in q \wedge k_i \in d_j} \log \frac{r_i(N - n_i - R + r_i)}{(R - r_i)(n_i - r_i)} \tag{3.21}$$

Para que essa equação seja efetiva é necessário ainda estimar quais são os documentos relevantes para a consulta. Para lidar com valores pequenos de r_i, é conveniente somar $0,5$ a cada um dos termos da equação anterior [7], levando a:

$$sim(d_j,q) \approx \sum_{k_i \in q \wedge k_i \in d_j} \log \frac{(r_i + 0,5)(N - n_i - R + r_i + 0,5)}{(R - r_i + 0,5)(n_i - r_i + 0,5)} \tag{3.22}$$

A Equação 3.22 ainda não pode ser computada sem estimativas de r_i e R. Uma possibilidade é considerar $R = r_i = 0$, assim temos:

$$sim(d_j,q) \approx \sum_{k_i \in q \wedge k_i \in d_j} \log \frac{N - n_i + 0,5}{n_i + 0,5} \tag{3.23}$$

Na falta de informação quanto à relevância dos documentos, o que é o mais usual, a equação anterior é a utilizada para computação do ranking no modelo probabilístico. Note que o componente IDF está presente, mas a frequência dos termos (TF) não é considerada, nem há normalização pelo tamanho dos documentos. Essa equação permite valores negativos de ranqueamento, e pode ter comportamentos anômalos. Uma alternativa para sanar essa anomalia é eliminar o fator n_i do numerador da Equação 3.23, levando a:

$$sim(d_j,q) \approx \sum_{k_i \in q \wedge k_i \in d_j} \log \frac{N + 0,5}{n_i + 0,5} \tag{3.24}$$

A Tabela 3.7 apresenta os escores obtidos no modelo probabilístico, computado pela Equação 3.24, para a consulta “eu sou".

Doc	Computação do Escore	Escore
d_1	$\log\left(\frac{4+0,5}{4+0,5}\right)$	$0,000$
d_2	$\log\left(\frac{4+0,5}{4+0,5}\right) + \log\left(\frac{4+0,5}{2+0,5}\right)$	$0,848$
d_3	$\log\left(\frac{4+0,5}{4+0,5}\right) + \log\left(\frac{4+0,5}{2+0,5}\right)$	$0,848$
d_4	$\log\left(\frac{4+0,5}{4+0,5}\right)$	$0,000$

Tabela 3.7: Cálculo da similaridade dos documentos da Figura 2.1 com relação à consulta “eu sou” no modelo probabilístico (Equação 3.24).

A principal **vantagem** do modelo probabilístico está na sua otimalidade, pois os documentos recuperados são ranqueados de forma decrescente de acordo com a probabilidade de serem relevantes,

com base na informação disponível no sistema. Entretanto, como **desvantagens**: (i) usualmente não há informação *a priori* sobre a relevância dos documentos, sendo necessário estimar essa relevância; (ii) o método não leva em consideração a frequência na qual um termo de indexação ocorre em um documento; e (iii) não é feita normalização pelo tamanho dos documentos.

3.8 Exercícios

Exercicio 3.1 A visibilidade de aplicativos e páginas Web é essencial para que o produto obtenha novos usuários. Suponha que você tenha que criar a descrição de um aplicativo com as mesmas funcionalidades do YouTube (porém menos poluído de propagandas), chamado NoAdTube. Elabore uma descrição para esse aplicativo de modo que: (i) demonstre suas principais funcionalidades aos usuários; (ii) tenha um bom escore para ranqueamento em consultas; (iii) esteja no limite de palavras permitidas pela PlayStore (entre 30 e 150). ■

Exercicio 3.2 Apresente as principais vantagens e desvantagens dos modelos Booleano, vetorial e probabilístico para o ranqueamento de documentos com relação a uma consulta. ■

Exercicio 3.3 Calcule a similaridade entre cada documento da coleção abaixo e a consulta "eu bebo" de acordo com os modelos Booleano, vetorial e probabilístico.

Ai se eu te pego, ai, ai se eu te pego.	Aí eu bebo, aí eu bebo! Bebo pra carai!	Só eu que bebo? Será que só eu que bebo.	Ai, ai, ai, ai esse amor, é bom demais
d_1	d_2	d_3	d_4

■

4. Avaliação da Recuperação

Para avaliar um sistema de recuperação de informação, é necessário medir o quão bem o sistema atende a necessidade de informação do usuário. Isso não é trivial, uma vez que a opinião dos usuários podem divergir quanto a documento atender ou não a uma mesma necessidade de informação. Apesar disso, é possível definir métricas para avaliar a qualidade dos resultados da recuperação como uma correlação com as preferências de uma população de usuários [1].

A **avaliação da recuperação** é um processo sistemático no qual se associa uma métrica quantitativa aos resultados produzidos por um sistema de RI em resposta a um conjunto de consultas de usuário. Essa métrica deve ser diretamente associada à relevância dos resultados para os usuários. A estratégia mais usual para computar tal métrica é comparar o resultado produzido pelo sistema com os resultados sugeridos por humanos para o mesmo conjunto de consultas [1].

Para ilustrar os resultados da avaliação da recuperação foi criado uma coleção de documentos relacionados a aplicativos de Jogos de Cartas disponíveis na *Play Store*[1]. A coleção é composta de 20 documentos contendo aplicativos para variados jogos de baralho. O conteúdo de cada documento é composto pelo título e a descrição do aplicativo. A Tabela 4.1 apresenta dados sobre a coleção de análise.

[1] `https://play.google.com/store/search?q=jogos%20de%20cartas`

#	Título	Palavras
1	Paciência	4.003
2	Truco Vamos: Jogo de cartas online grátis	993
3	Buraco Jogatina: Jogo de Cartas e Canastra Grátis	1.313
4	MegaJogos - Jogos de Cartas e Jogos de Tabuleiro	1.309
5	Paciência Spider	676
6	Jogos de Cartas Online - Jogo de Baralho Grátis	1.165
7	Paciência Spider	1.581
8	ZingPlay Jogos - Truco - Buraco - Tranca - Cacheta	2.663
9	Pyramid Solitaire Saga	2.152
10	Solitário	1.418
11	Cacheta Online Grátis: pife - Jogo de Cartas	815
12	Paciência - Solitário	1.331
13	Solitário - Paciência Solitário Jogos De Cartas	3.158
14	Buraco Real - Jogo de Cartas	1.509
15	Truco Online - Paulista e Mineiro	680
16	Canastra	281
17	Governor of Poker 3 - Texas Holdem Pôquer Online	3.962
18	Buraco, Canastra, Tranca - Jogos de Cartas Online	1.035
19	Copas	907
20	Buraco ZingPlay - Jogo de Cartas	1.806

Tabela 4.1: Coleção de documentos sobre aplicativos de Jogos de Cartas presentes na *PLay Store*.

4.1 Métricas de Recuperação

4.1.1 Precisão e Revocação

As métricas precisão e revocação são baseadas na classificação binária de relevância (indicando se o documento é relevante ou não à pesquisa). **Revocação** é o número de documentos relevantes recuperados por uma consulta dividido pelo número total de documentos relevantes existentes na base de dados. **Precisão** é definida como o número de documentos relevantes recuperados pela busca dividido pelo número total de documentos recuperados.

Considere uma requisição de informação I e seu conjunto de documentos relevantes R. Seja $|R|$ o número de documentos nesse conjunto. Suponha que um determinado algoritmo de recuperação tenha retornado um conjunto A de documentos como resposta à requisição I, e $|A|$ é o número de documentos nesse conjunto. A Figura 4.1 trás uma ilustração desses conjuntos. Formalmente, temos revocação e precisão como:

$$\begin{aligned} \text{Revocação: } r &= \frac{|R \cap A|}{R} \\ \text{Precisão: } p &= \frac{|R \cap A|}{A} \end{aligned} \tag{4.1}$$

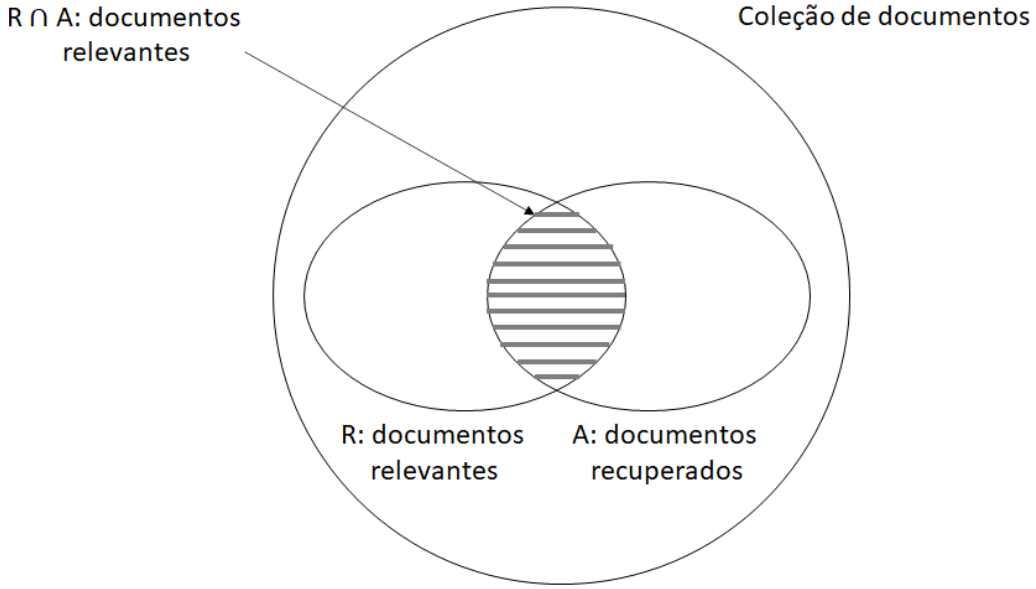


Figura 4.1: Revocação e precisão para uma determinada requisição de informação [1].

Conforme a definição dada, precisão e revocação supõem que todos os documentos no conjunto resposta A foram vistos pelo usuário. Entretanto, o usuário normalmente não é apresentado a todos os documentos recuperados de uma vez. Em vez disso, os documentos são ordenados e apresentados de acordo com a função de ranqueamento. O usuário então analisa essa lista começando pelo documento do topo. Nesse caso, as medidas de precisão e revocação variam conforme o número de documentos que são apresentados ao usuário. Assim, uma avaliação adequada requer a plotagem da curva de precisão vs. revocação [1].

Considere que na coleção de referência sobre jogos de cartas o conjunto de documentos relevantes R_1 para a consulta “Buraco Online"(q_1) foi determinado por um especialista como:

$$R_1 = \{d_3, d_4, d_6, d_{14}, d_{18}, d_{20}\} \tag{4.2}$$

Note que, de acordo com o especialista temos seis documentos relevantes para a consulta. Considere o ranqueamento dado pelo modelo vetorial assumindo que um documento d_j é relevante a uma consulta q se $sim_{j,q} \geq 0.05$ conforme a Tabela 4.2:

Pos	Doc.	Título	$sim_{j,q}$
1	d_{18}*	Buraco, Canastra, Tranca - Jogos de Cartas Online	0,229
2	d_6*	Jogos de Cartas Online - Jogo de Baralho Gratis	0,181
3	d_3*	Buraco Jogatina: Jogo de Cartas e Canastra Grátis	0,165
4	d_{14}*	Buraco Real - Jogo de Cartas	0,142
5	d_4*	MegaJogos - Jogos de Cartas e Jogos de Tabuleiro	0,140
6	d_{20}*	Buraco ZingPlay - Jogo de Cartas	0,135
7	d_8	ZingPlay Jogos - Truco - Buraco - Tranca - Cacheta	0,071
8	d_{11}	Cacheta Online Grátis: pife - Jogo de Cartas	0,056

Tabela 4.2: Ranqueamento do modelo vetorial para a consulta “Buraco Online"sobre a coleção Jogos de Cartas.

Onde documentos marcados com asterisco fazem parte do conjunto de documentos relevantes R_1 indicado pelo especialista humano. Ao examinar esse ranqueamento, iniciando pelo primeiro

documento observamos que d_{18} é relevante e corresponde a um sexto dos documentos relevantes; assim, considerando um documento temos precisão de 100% e revocação de $16,67\%$. Já considerando o segundo documento, d_6 também é relevante, logo a precisão continua 100% $(2/2)$ e, considerando os dois documentos termos dois sextos dos documentos relevantes, logo $33,33\%$ de revocação. Ao fazer essa análise para todos os documentos recuperados temos a Tabela 4.3.

Pos	Doc.	Precisão	Revocação
1	d_{18}*	$1/1 = 100\%$	$1/6 = 17\%$
2	d_6*	$2/2 = 100\%$	$2/6 = 33\%$
3	d_3*	$3/3 = 100\%$	$3/6 = 50\%$
4	d_{14}*	$4/4 = 100\%$	$4/6 = 67\%$
5	d_4*	$5/5 = 100\%$	$5/6 = 83\%$
6	d_{20}*	$6/6 = 100\%$	$6/6 = 100\%$
7	d_8	$6/7 = 86\%$	$6/6 = 100\%$
8	d_{11}	$6/8 = 75\%$	$6/6 = 100\%$

Tabela 4.3: Valores de precisão e revocação para o ranqueamento obtido pelo modelo vetorial para a consulta “Buraco Online"sobre a coleção Jogos de Cartas.

Considere agora os resultados do modelo Booleano de ranqueamento aplicado sobre a mesma consulta e a mesma coleção de documentos, apresentados na Tabela 4.4 (em caso de empate foi adotada a ordem numérica dos documentos):

Pos	Doc.	Título	$sim_{j,q}$
3	d_3*	Buraco Jogatina: Jogo de Cartas e Canastra Grátis	1
5	d_4*	MegaJogos - Jogos de Cartas e Jogos de Tabuleiro	1
2	d_6*	Jogos de Cartas Online - Jogo de Baralho Gratis	1
1	d_{18}*	Buraco, Canastra, Tranca - Jogos de Cartas Online	1
6	d_{20}*	Buraco ZingPlay - Jogo de Cartas	1
4	d_1	Paciência	0
7	d_2	Truco Vamos: Jogo de cartas online grátis	0
8	d_5	Paciência Spider	0

Tabela 4.4: Ranqueamento do modelo Booleano para a consulta “Buraco Online"sobre a coleção Jogos de Cartas.

Vejamos agora, na Tabela 4.5 a revocação e precisão para a recuperação apresentada na Tabela 4.4.

Pos	Doc.	Precisão	Revocação
1	d_3*	$1/1 = 100\%$	$1/6 = 17\%$
2	d_4*	$2/2 = 100\%$	$2/6 = 33\%$
3	d_6*	$3/3 = 100\%$	$3/6 = 50\%$
4	d_{18}*	$4/4 = 100\%$	$4/6 = 67\%$
5	d_{20}*	$5/5 = 100\%$	$5/6 = 83\%$
6	d_1	$5/6 = 83\%$	$5/6 = 83\%$
7	d_2	$5/7 = 71\%$	$5/6 = 83\%$
8	d_5	$5/8 = 63\%$	$5/6 = 83\%$

Tabela 4.5: Valores de precisão e revocação para o ranqueamento obtido pelo modelo Booleano para a consulta “Buraco Online"sobre a coleção Jogos de Cartas.

Através das tabelas 4.3 e 4.5 podemos ter uma intuição de que o modelo vetorial obteve melhores resultados de recuperação, porém não temos ainda um valor número individual para quantificar essa diferença. As métricas mais utilizadas para comparação de algoritmos de recuperação de informação serão apresentadas nas seções a seguir.

4.2 Métricas de Avaliação

4.2.1 Média das Precisões Médias

Seja R_i o conjunto de documentos relevantes para a consulta q_i, $|R_i|$ o número de documentos relevantes para a consulta q_i e $R_i[k]$ uma referência ao k-ésimo documento no ranking de q_i. Então, $P(R_i[k])$ é a precisão quando o documento $R_i[k]$ é observado no ranking de q_i. Se aquele documento não for recuperado, o que é comum em buscas reais, assumimos $P(R_i[k]) = 0$ [1]. Assim podemos definir a **precisão média** para a consulta q_i como:

$$MAP_i = \frac{1}{|R|} \sum_{k \in R_i} P(R_i[k]) \tag{4.3}$$

Como exemplo, considere os resultados obtidos pelos modelos vetorial e Booleano apresentados nas tabelas 4.3 e 4.5. Para o modelo vetorial, os valores de precisão após cada documento relevante ter sido observado foram 1, 1, 1, 1, 1, 1, 0,86, 0,75. Assim, a precisão média para essa consulta é:

$$MAP_1 = \frac{1+1+1+1+1+1+0,86+0,75}{8} = 0,951 \tag{4.4}$$

Já para o modelo Booleano, os valores de precisão ao observar cada documento recuperado foram 1, 1, 1, 1, 1, 0,83, 0,71, 0,63. Logo, a precisão média é:

$$MAP_1 = \frac{1+1+1+1+1+0,83+0,71+0,63}{8} = 0,896 \tag{4.5}$$

É recomendável avaliar um algoritmo de ranqueamento sob várias consultas a fim de determinar sua efetividade. Nesse caso, podemos obter a **média das precisões médias** de um conjunto N_q de consultas como segue:

$$MAP = \frac{1}{|N_q|} \sum_{i \in N_q} MAP_i \tag{4.6}$$

4.2.2 Curva de Precisão vs. Revocação

A relação entre precisão e revocação pode ser representada através de um gráfico, onde o eixo x representa a revocação e o eixo y a precisão. Ao invés de usar a precisão e revocação em cada posição do ranqueamento, essa curva é comumente plotada usando os níveis de recuperação em 0%, 10%, 20%, ..., 100%. A curva usualmente tem um declive negativo, representando a relação inversa entre precisão e revocação [2]. A Figura 4.2 apresenta os gráficos de precisão e revocação para os modelos vetorial e Booleanos aplicados à coleção Jogos de Cartas com a consulta “Buraco Online".

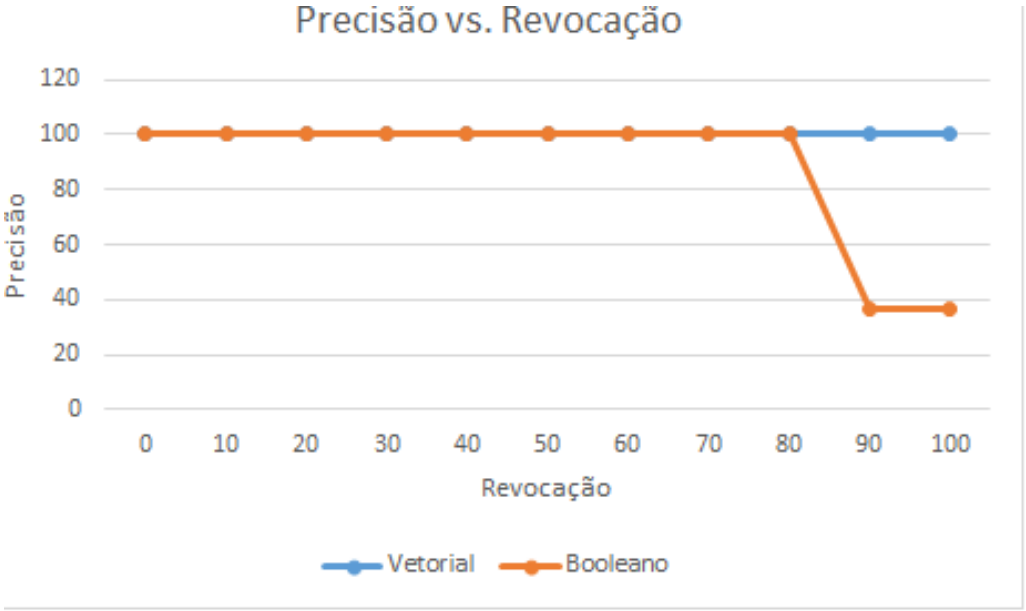


Figura 4.2: Valores de precisão vs. revocação para os modelo vetorial e Booleano de recuperação.

Seja $r_j, j \in \{0,1,2,...,10\}$, uma referência ao j-ésimo nível padrão de revocação (isto é, r_3 é uma referência ao nível de revocação de 30%), então:

$$P(r_j) = \max_{\forall r | r_j \leq r} P(r) \tag{4.7}$$

o que determina a **precisão interpolada** no j-ésimo nível padrão de revocação é a precisão máxima conhecida entre todos os níveis de revocação maiores ou iguais a r_j [1].

No exemplo anterior, os valores de precisão e revocação foram calculados para um consulta individual. Como mencionado anteriormente, é comum avaliar algoritmos de recuperação de informação sobre diversas consultas de teste. Nesse caso, para cada consulta, uma curva de precisão versus revocação distinta é gerada para a consulta de teste. Para avaliar a qualidade da recuperação sobre um conjunto de N_q consultas, podemos, de forma análoga ao adotado na métrica anterior, calcular a média das precisões para cada nível de revocação:

$$\overline{P}(r_j) = \frac{1}{|N_q|} \sum_{i \in N_q} P_i(r_j) \tag{4.8}$$

As médias dos valores de precisão-revocação podem então ser usadas para comparar a qualidade de diferentes algoritmos de recuperação de informação. Essa métrica tem sido amplamente utilizada para avaliar a qualidade de algoritmos de recuperação. Entretanto, sua principal **desvantagem** é que a estimativa de revocação máxima para uma consulta requer conhecimento detalhado de todos os documentos da coleção. Ademais, para coleções grandes, como da Web a revocação máxima não pode ser computada de forma precisa. Já suas **vantagens** residem no fato de ser simples de calcular e de permitir a comparação direta de diferentes estratégias de ranqueamento [1].

4.2.3 F-score

A média harmônica, mais conhecida como **F-score**, é uma outra maneira de combinar precisão e revocação em um único número [8]. O F-score é computado como:

$$F(j) = \frac{2}{\frac{1}{r_j} + \frac{1}{P(j)}} \tag{4.9}$$

onde $r(j)$ é a revocação na j-ésima posição do ranking, $P(j)$, a precisão nessa mesma posição e $F(j)$ a média harmônica na j-ésima posição do ranking. O F-score é 0 quando nenhum documento relevante foi recuperado e 1 quando todos os documentos recuperados são relevantes.

4.3 Exercícios

Exercicio 4.1 Como usuário de um mecanismo de busca na Web (ex.: Google, Bing), o que você prioriza nas suas consultas: a precisão ou a revocação nos resultados? Justifique. ■

Exercicio 4.2 Considerando que dois modelos de recuperação de informação foram aplicados a uma determinada consulta numa coleção com 50 documentos e retornaram os seguintes resultados:

$$\begin{aligned} A_1 &= \{d_7, d_8, d_{15}, d_{17}, d_6, d_1, d_9, d_5\} \\ A_2 &= \{d_8, d_7, d_1, d_{15}, d_6, d_{17}, d_5, d_9\} \end{aligned} \tag{4.10}$$

Assumindo ainda que os documentos classificados como relevantes para essa consulta por um especialista humano foram:

$$R = \{d_5, d_8, d_{17}\} \tag{4.11}$$

1. ~~Apresente e compare as curvas de precisão vs. revocação de cada um desses modelos.~~
2. Calcule a média das precisões de cada um desses modelos.
3. É possível concluir que o modelo 1 é melhor do que o modelo 2?

■

Exercicio 4.3 Para melhorar ainda mais os resultados de uma consulta, o Google usa uma variedade de informações do seu perfil, como sua localização, idade, gênero, histórico de pesquisas, entre outros. Você considera essa invasão de privacidade nociva ou acredita que a personalização dos resultados é interessante? Justifique. [a] ■

[a] Para quem quiser se aprofundar no assunto, o documentário “O Dilema das redes"traz uma reflexão interessante.

Bibliografia

Artigos

[3] Karen Sparck Jones. “A statistical interpretation of term specificity and its application in retrieval”. Em: *Journal of documentation* (1972) (ver página 23).

[5] H. Luhn. “A statistical approach to mechanized encoding and searching of literary information”. Em: *IBM Journal of Research and Development* 1 (1957), páginas 309–317 (ver página 22).

[7] S. E. Robertson e K. Sparck Jones. “Relevance weighting of search terms”. Em: *Journal of the American Society for Information Science* 27.3 (1976), páginas 129–146 (ver páginas 27, 29).

[8] W. M. Shaw, Robert Burgin e Patrick Howell. “Performance Standards and Evaluations in IR Test Collections: Cluster-Based Retrieval Models”. Em: *Inf. Process. Manage.* 33.1 (jan. de 1997), páginas 1–14 (ver página 36).

[9] Herbert A Simon e M Greenberger. “Designing Organizationsfor an Information-Rich World”. Em: *Martin Greenberger, Computers, Communication, and the Public ...* (1971) (ver página 7).

Livros

[1] Ricardo Baeza-Yates e Berthier Ribeiro-Neto. *Modern Information Retrieval: The Concepts and Technology behind Search*. 2ª edição. Pearson, 2011 (ver páginas 8–11, 15, 19–22, 28, 31, 33, 35, 36).

[2] Ramez Elmasri e Sham Navathe. *Fundamentals of Database Systems*. 7ª edição. Pearson, 2016 (ver páginas 6, 7, 11, 12, 16, 17, 35).

[4] Amy N Langville e Carl D Meyer. *Google’s PageRank and beyond: The science of search engine rankings*. Princeton university press, 2011 (ver página 11).